Metody Optymalizacji
Projekt: PFSP

Jakub Wasilewski 263852

10.04.2026

Spis treści

1 Sformułowanie zadania **2**

2 Sposób rozwiązywania zadania **2**

3 Metody użyte do rozwiązania zadania **2**

4 Implementacja **2**
4.1 Algorytm losowy 2
4.2 Algorytm zachłanny 2
4.3 Symulowane wyżarzanie (SA) 3
4.4 Algorytm ewolucyjny (EA) 3
4.5 Kontrola budżetu 4

5 Pliki wejściowe **4**

6 Procedura badawcza **4**

7 Wyniki badań przed strojeniem **4**

8 Strojenie parametrów **5**
8.1 Rozmiar populacji (`pop_size`) 5
8.2 Operatory genetyczne 5
8.3 Prawdopodobieństwo krzyżowania (`Px`) 6
8.4 Prawdopodobieństwo mutacji (`Pm`) 6
8.5 Strojenie parametrów SA 7
8.5.1 Wnioski 7
8.6 Podsumowanie strojeń EA 8

9 Finalne porównanie algorytmów **9**
9.1 Wykresy przebiegu EA 9

10 Analiza wyników i wnioski **10**
10.1 Ranking algorytmów 10
10.2 Kluczowe obserwacje 11

1 Sformułowanie zadania

Celem zadania była implementacja i przebadanie metaheurystyki Algorytmu Ewolucyjnego (EA) dla permutacyjnego problemu przepływowego (PFSP – *Permutation Flow Shop Problem*) oraz porównanie jej z metodami nieewolucyjnymi: algorytmem zachłannym (greedy), symulowanym wyżarzaniem (SA) i losowym przeszukiwaniem.

W PFSP rozpatrywano n zadań i m maszyn. Każde zadanie musiało być wykonane na każdej maszynie w tej samej ustalonej kolejności (maszyna $1 \to 2 \to \ldots \to$ m). Czas przetwarzania zadania j na maszynie i wynosił p_{ij}. Poszukiwano permutacji zadań minimalizującej **sumę czasów ukończenia wszystkich zadań na ostatniej maszynie** ($\sum_{j=1}^{J} c(x_j, M)$, tzw. *total completion time*). Nie jest to makespan ($C_{\max}$, czyli czas zakończenia wyłącznie ostatniego zadania), lecz suma wartości $c(x_j, M)$ dla każdego zadania j w kolejności permutacji.

2 Sposób rozwiązywania zadania

Rozwiązania były kodowane jako permutacje n zadań. Ocena rozwiązania polegała na obliczeniu sumy czasów ukończenia wszystkich zadań na ostatniej maszynie ($\sum C_j$) poprzez symulację harmonogramu: dla każdej maszyny i każdego zadania (w kolejności permutacji) czas zakończenia wyznaczany był jako maksimum czasu zwolnienia maszyny i czasu zakończenia poprzedniego zadania na tej samej maszynie, powiększony o czas przetwarzania. Na końcu sumowane były czasy ukończenia na ostatniej maszynie dla wszystkich zadań. Wszystkie metaheurystyki operowały bezpośrednio na permutacjach.

3 Metody użyte do rozwiązania zadania

- Algorytm losowy (random)
- Algorytm zachłanny (greedy, multi-start)
- Symulowane wyżarzanie (SA)
- Algorytm ewolucyjny (EA)

4 Implementacja

4.1 Algorytm losowy

- Zastosowano proste losowe przeszukiwanie przestrzeni rozwiązań.
- W każdej iteracji generowana była losowa permutacja n zadań i obliczana jej wartość funkcji celu ($\sum C_j$).
- **Parametry:** liczba iteracji = budżet B.
- **Log:** co iterację zapisywany był bieżący koszt; Logger śledził best/avg/worst w czasie.

4.2 Algorytm zachłanny

- Zaimplementowano wielostartowy algorytm konstrukcyjny.
- Dla każdego punktu startowego (zadania) budowana była permutacja – w każdym kroku kolejne zadanie wstawiano na pozycję minimalizującą bieżącą wartość $\sum C_j$.
- **Multi-start:** przeprowadzano uruchomienia dla różnych zadań startowych; zwracane było najlepsze znalezione rozwiązanie.

- **Parametry:** liczba restartów (domyślnie = liczba zadań).

4.3 Symulowane wyżarzanie (SA)

- Zaimplementowano metaheurystykę inspirowaną procesem wyżarzania metali.
- **Rozwiązanie startowe:** losowa permutacja (nowe w każdym uruchomieniu).
- **Sąsiedztwo:** operator swap – zamiana dwóch losowych pozycji w permutacji.
- **Akceptacja:**
  - Ruch poprawiający ($\Delta < 0$): zawsze był akceptowany.
  - Ruch pogarszający: akceptowany z prawdopodobieństwem $\exp(-\Delta/T)$.
- **Schemat chłodzenia:** geometryczny, $T_{t+1} = \alpha \cdot T_t$, gdzie α to współczynnik chłodzenia.
- **Temperatura początkowa T_0:** estymowana była automatycznie ze wzoru $T_0 = -\overline{\Delta^+}/\ln(p_0)$, gdzie $\overline{\Delta^+}$ to średni dodatni delta z 200 losowych ruchów swap, a $p_0 = 0{,}8$ to docelowe prawdopodobieństwo akceptacji ruchu pogarszającego na starcie.
- **Kryterium stopu:** po wykonaniu dokładnie B ewaluacji (kroków pętli).

4.4 Algorytm ewolucyjny (EA)

- Zaimplementowano metaheurystykę inspirowaną ewolucją biologiczną.
- **Inicjalizacja:** tworzona była populacja losowych permutacji (rozmiar `pop_size`), każda oceniana – koszt = 1 ewaluacja.
- **Selekcja:** turniejowa – losowano `tour_size` osobników i wybierano najlepszego.
- **Krzyżowanie:**
  - **OX** (Ordered Crossover) – kopiowany był segment z rodzica 1, brakujące elementy uzupełniano w kolejności z rodzica 2, zachowując względną kolejność.
  - **PMX** (Partially Mapped Crossover) – wymieniano segmenty i naprawiano konflikty przez mapowanie pozycji.
  - **CX** (Cycle Crossover) – zachowywane były bezwzględne pozycje genów przez cykl mapowania.
  - Krzyżowanie stosowane było z prawdopodobieństwem `Px`; w przeciwnym razie kopiowany był rodzic 1.
- **Mutacja:**
  - **SWAP** – zamiana dwóch losowych pozycji w permutacji.
  - **INVERSION** – odwrócenie losowego segmentu permutacji.
  - Mutacja stosowana była z prawdopodobieństwem `Pm`.
- **Kryterium stopu:** po wykonaniu dokładnie B ewaluacji.
- **Budżet:** $\texttt{pop_size} \cdot (\texttt{gen} + 1) = B$, gdzie $+1$ uwzględnia koszt inicjalizacji populacji. Stąd $\texttt{gen} = (B - \texttt{pop_size})/\texttt{pop_size}$.

4.5 Kontrola budżetu

Wszystkie algorytmy korzystały ze wspólnego licznika wywołań funkcji celu (`eval_counter`) w klasie `PfspInstance`. Po każdym eksperymencie weryfikowany był assert: dla EA – $N_RUNS \cdot B$, dla SA – $N_RUNS \cdot (B + 1)$ (dodatkowe wywołanie z losowego startu).

5 Pliki wejściowe

Wykorzystano instancje z zestawu benchmarkowego Taillarda:

- **Łatwe:** tai20_5 (20 zadań, 5 maszyn), tai20_10 (20 zadań, 10 maszyn), tai20_20 (20 zadań, 20 maszyn)
- **Średnie:** tai100_10 (100 zadań, 10 maszyn), tai100_20 (100 zadań, 20 maszyn)
- **Trudne:** tai500_20 (500 zadań, 20 maszyn)

6 Procedura badawcza

- Budżet obliczeniowy: $B = 100\,000$ wywołań funkcji celu dla wszystkich konfiguracji.
- Liczba powtórzeń: $N = 5$ niezależnych uruchomień.
- Miara jakości: **średnia** (avg) wyników z N powtórzeń – odporna na pojedyncze szczęśliwe wyniki.
- Parametry bazowe EA: `pop_size=100`, `Px=0.7`, `Pm=0.1`, `tour_size=5`, krzyżowanie OX, mutacja SWAP, inicjalizacja losowa.
- Parametry bazowe SA: T_0 auto-estymowane, $\alpha = 0{,}995$.

7 Wyniki badań przed strojeniem

Poniższa tabela przedstawia wyniki uzyskane z domyślnymi parametrami ($N = 5$ powtórzeń, $B = 100\,000$). Dla EA zastosowano: `pop=100`, `gen=999`.

Tabela 1: Wyniki bazowe (przed strojeniem)

Instancja	EA best	EA avg	EA std	SA best	SA avg	SA std
tai20_5	14094	14190	75.7	14163	14359	196.2
tai20_10	21432	21692	257.2	21001	21547	436.8
tai20_20	33972	34451	268.6	34320	34422	60.0
tai100_10	314007	317724	2968.3	309957	311563	1634.6
tai100_20	386480	389944	2594.4	385105	386373	1391.6
tai500_20	7218198	7238642	13201.4	6998539	7027898	17267.2

Wnioski (etap bazowy):

- Na małych instancjach (tai20_*) EA z domyślną populacją 100 okazał się konkurencyjny lub lepszy od SA.
- Na dużych instancjach (tai100_*, tai500_20) SA wyraźnie dominowało – przewaga rosła ze skalą problemu (dla tai500_20 SA było lepsze o ok. 3%).
- Duże odchylenie standardowe EA wskazywało na niestabilność przy małej populacji.

8 Strojenie parametrów

Strojenie przeprowadzono iteracyjnie, każdorazowo utrwalając najlepszy parametr przed przejściem do kolejnego. Budżet $B = 100\,000$ dla wszystkich konfiguracji.

8.1 Rozmiar populacji (`pop_size`)

Przetestowano wartości: 100, 200, 500, 1000, 5000, 10000. Liczba generacji dobierana była automatycznie: $\texttt{gen} = (B - \texttt{pop})/\texttt{pop}$.

Tabela 2: Strojenie `pop_size` – avg z 5 uruchomień

pop_size (gen)	tai20_5	tai20_10	tai20_20	tai100_10	tai100_20	tai500_20
100 (999)	14190	21692	34451	317724	389944	**7238642**
200 (499)	14250	21232	34118	315830	389927	7263246
500 (199)	14119	21091	33956	315084	389878	7289871
1000 (99)	14083	20997	33947	314121	390081	7298239
5000 (19)	**14054**	**20975**	**33837**	331266	407276	7623762
10000 (9)	14296	21489	34371	341050	419076	7738554

Wnioski: Ujawniła się odwrotna zależność między optymalnym `pop_size` a trudnością instancji. Na małych instancjach duża populacja (5000) wygrywała – przestrzeń rozwiązań była mała, a różnorodność genetyczna okazała się ważniejsza niż liczba generacji. Na dużych instancjach mała populacja z wieloma generacjami (100, 999 gen) wygrywała – przestrzeń była ogromna, algorytm potrzebował głębokiej iteracyjnej poprawy, a nie szerokiej inicjalizacji. Przy `pop=5000` na tai100/tai500 liczba generacji spadała do 9–19, co praktycznie uniemożliwiało ewolucję.

Przyjęte wartości: `pop=5000` dla instancji tai20_*, `pop=500` dla tai100_* i tai500_20.

8.2 Operatory genetyczne

Przetestowano macierz 3 operatorów krzyżowania $\times$ 2 operatorów mutacji = 6 kombinacji, przy domyślnych `Px=0.7`, `Pm=0.1`.

Tabela 3: Strojenie operatorów – avg z 5 uruchomień

Operatory	tai20_5	tai20_10	tai20_20	tai100_10	tai100_20	tai500_20
OX+SWAP	**14050**	**20976**	**33804**	**314976**	**388839**	**7269054**
OX+INV	14050	20985	33839	320988	394008	7396331
PMX+SWAP	14096	21155	34012	316063	390552	7295316
PMX+INV	14114	21122	34031	323640	399469	7475300
CX+SWAP	14251	21392	34253	318466	392366	7373814
CX+INV	14200	21432	34289	326987	405567	7536259

Wnioski: Kombinacja OX+SWAP wygrała we wszystkich sześciu instancjach.

SWAP okazał się lepszy od INVERSION niezależnie od krzyżowania – w PFSP kluczowa jest *względna kolejność* zadań, a nie bezwzględne pozycje. INVERSION odwracał segment, niszcząc starannie wypracowane przez OX bloki kolejności. SWAP zamieniał tylko dwa elementy, zachowując resztę struktury.

CX wypadł najgorzej – jest zaprojektowany do zachowania bezwzględnych pozycji genów, co nie ma znaczenia w PFSP.

PMX uplasował się pośrodku – częściowe mapowanie dawało lepsze wyniki niż CX, ale gorsze niż OX. OX najlepiej zachowywał ciągłe bloki względnej kolejności, co odpowiadało strukturze dobrego harmonogramu w PFSP.

Przyjęta konfiguracja: `crossover = OX`, `mutation = SWAP`.

8.3 Prawdopodobieństwo krzyżowania (`Px`)

Przetestowano wartości: 0.50, 0.70, 0.90, 0.95, 0.98. Zastosowano operatory OX+SWAP oraz per-instancja `pop_size`.

Tabela 4: Strojenie `Px` – avg z 5 uruchomień

Px	tai20_5	tai20_10	tai20_20	tai100_10	tai100_20	tai500_20
0.50	14067	20977	33858	318557	391250	7318585
0.70	14049	20978	**33769**	316222	390330	7273954
0.90	**14045**	**20947**	33773	**311625**	387485	7205858
0.95	14058	20964	33803	313028	**384112**	7206759
0.98	14049	20963	33831	311889	385569	**7185858**

Wnioski: Im trudniejsza instancja, tym wyższe `Px` okazywało się korzystniejsze. Na małych instancjach różnice były marginalne (szum przy $N = 5$). Na dużych instancjach wzrost `Px` od 0.50 do 0.98 dał wyraźną poprawę (tai500_20: $-1{,}8\%$).

Krzyżowanie jest operatorem budowania rozwiązań z fragmentów rodziców. W dużej przestrzeni dobre częściowe struktury były rzadkie – krzyżowanie pozwalało je łączyć. Przy niskim `Px` EA degenerował się do lokalnego przeszukiwania z mutacją.

Przyjęte wartości per-instancja: tai20_5: 0.90, tai20_10: 0.90, tai20_20: 0.70, tai100_10: 0.90, tai100_20: 0.95, tai500_20: 0.98.

8.4 Prawdopodobieństwo mutacji (`Pm`)

Przetestowano wartości: 0.01, 0.05, 0.10, 0.20, 0.40. Zastosowano konfigurację: OX+SWAP, per-instancja `pop_size` i `Px`.

Tabela 5: Strojenie `Pm` – avg z 5 uruchomień

Pm	tai20_5	tai20_10	tai20_20	tai100_10	tai100_20	tai500_20
0.01	**14046**	20968	33812	317763	388332	7218867
0.05	14047	**20947**	**33782**	314825	387514	7207249
0.10	14062	20962	33783	313286	385259	7189132
0.20	14074	20999	33818	311163	383801	7180216
0.40	14088	21049	33862	**310342**	**383251**	**7168178**

Wnioski: Zaobserwowano odwrotny wzorzec niż przy `Px`: im trudniejsza instancja, tym wyższe `Pm` okazywało się korzystniejsze. Na tai100/tai500 trend był monotonicznie rosnący – `Pm=0.40` wygrało wyraźnie (tai500_20: poprawa o 0.7% vs `Pm=0.01`).

Przy dużej przestrzeni i wysokim `Px` krzyżowanie dominowało reprodukcję – populacja szybko traciła różnorodność i zbiegała do lokalnego minimum. Mutacja przy wysokim `Pm` pełniła rolę dywersyfikatora, regularnie wstrzykując perturbacje. Było to szczególnie istotne gdy przestrzeń była wielowymiarowa i pełna lokalnych minimów. `Px` i `Pm` działały komplementarnie – na trudnych instancjach oba parametry powinny być wysokie.

Przyjęte wartości per-instancja: tai20_5: 0.01, tai20_10: 0.05, tai20_20: 0.05, tai100_10: 0.40, tai100_20: 0.40, tai500_20: 0.40.

8.5 Strojenie parametrów SA

Przetestowano macierz kombinacji dwóch parametrów:

- **Współczynnik chłodzenia** $\alpha \in \{0.990, 0.995, 0.999\}$
- **Mnożnik temperatury początkowej** $\in \{0.5\times, 1\times, 5\times, 10\times\}$ auto-estymaty ($T_0 = -\overline{\Delta^+}/\ln(0.8)$)

Łącznie 12 kombinacji per instancja, $N = 5$ powtórzeń, $B = 100\,000$.

Tabela 6: Strojenie SA – avg z 5 uruchomień (wybrane wyniki)

α	t0 mult	tai20_5	tai20_10	tai20_20	tai100_10	tai100_20	tai500_20
0.990	0.5×	14423	21812	34490	312317	387086	**6997211**
0.990	1×	14251	21741	34415	313499	385459	7027637
0.990	5×	14316	22033	34506	312030	385404	7011055
0.990	10×	14262	21790	34714	312374	386978	7017959
0.995	0.5×	14277	21609	34383	313206	385331	7027496
0.995	1×	14334	21588	34611	313006	385238	7024425
0.995	5×	14290	21707	34554	313482	385612	7035818
0.995	10×	14278	21700	34447	313060	387038	7005802
0.999	0.5×	14279	21585	34249	313113	383319	7002763
0.999	1×	14197	21588	**34213**	**310930**	385280	7019722
0.999	5×	14205	21452	34452	311430	**382694**	7013917
0.999	10×	**14129**	**21291**	34290	311087	385608	7008148

8.5.1 Wnioski

Współczynnik chłodzenia: $\alpha = 0.999$ wygrał na 5 z 6 instancji. Wolne chłodzenie pozwalało algorytmowi spędzić więcej czasu w fazie eksploracji przy umiarkowanej temperaturze – kluczowe gdy przestrzeń rozwiązań była złożona. Wyjątek stanowiła tai500_20, gdzie $\alpha = 0.990$ okazał się najlepszy, jednak różnice między wszystkimi konfiguracjami na tej instancji wyniosły poniżej 0.2% i mieściły się w szumie statystycznym przy $N = 5$.

Mnożnik T_0: nie zaobserwowano jednoznacznego trendu – optymalna wartość zależała od instancji. Na małych instancjach (tai20_5, tai20_10) wyższe wartości (10×) dawały lepsze wyniki: przy wolnym chłodzeniu wysoka T_0 zapewniała długą fazę eksploracji, a mała przestrzeń pozwalała ją w pełni wykorzystać. Na dużych instancjach (tai100_10, tai100_20) optymalne okazały się wartości 1×–5×, zaś na tai500_20 niska wartość (0.5×) z szybszym chłodzeniem działała najlepiej – zbyt wysoka T_0 oznaczała trwonienie budżetu na niemal losowe akceptacje zanim algorytm wszedł w fazę eksploatacji.

Przyjęte wartości per-instancja:

Instancja	α	T_0 mult
tai20_5	0.999	10×
tai20_10	0.999	10×
tai20_20	0.999	1×
tai100_10	0.999	1×
tai100_20	0.999	5×
tai500_20	0.990	0.5×

8.6 Podsumowanie strojeń EA

Tabela 7: Zestawienie finalnych parametrów per instancja

	EA					SA	
Instancja	`pop`	`gen`	`Px`	`Pm`	Operatory	α	T_0 mult
tai20_5	5000	19	0.90	0.01	OX+SWAP	0.999	10×
tai20_10	5000	19	0.90	0.05	OX+SWAP	0.999	10×
tai20_20	5000	19	0.70	0.05	OX+SWAP	0.999	1×
tai100_10	500	199	0.90	0.40	OX+SWAP	0.999	1×
tai100_20	500	199	0.95	0.40	OX+SWAP	0.999	5×
tai500_20	500	199	0.98	0.40	OX+SWAP	0.990	0.5×

Kluczowe obserwacje:

1. Najważniejszym parametrem okazał się `pop_size` – wpływ na wyniki był największy i jakościowo różny dla małych vs dużych instancji.
2. Operatory OX+SWAP zdominowały wszystkie instancje. INVERSION i CX nie wniosły korzyści dla PFSP.
3. `Px` i `Pm` wykazały lustrzany wzorzec: na trudnych instancjach oba powinny być wysokie. Krzyżowanie eksplorowało przez rekombinację, mutacja utrzymywała różnorodność.
4. SA konsekwentnie wygrywało z EA na dużych instancjach, niezależnie od konfiguracji EA. Różnica na tai500_20 wynosiła ok. 2–3% na korzyść SA.

9 Finalne porównanie algorytmów

Porównanie przeprowadzono z najlepszymi konfiguracjami znalezionymi w etapie strojenia. Parametry dla każdej metody zestawiono w tabeli w sekcji 8. Zastosowano budżet obliczeniowy $B = 200\,000$ wywołań funkcji celu. Metody niedeterministyczne (Random, EA, SA) uruchomiono $N = 10$ razy niezależnie; wyniki greedy były deterministyczne (jeden przebieg multi-start). Przetestowano wszystkie instancje zestawu Taillarda.

Tabela 8: Finalne porównanie – wyniki z 10 uruchomień ($B = 200\,000$)

	Random		Greedy	EA			SA		
Instancja	best	avg	best	best	avg	std	best	avg	std
tai20_5	14875	15038.3	15403	**14041**	**14042.9**	5.7	14104	14261.3	102.6
tai20_10	21999	22563.6	24611	**20911**	**20952.9**	15.2	21186	21360.6	121.5
tai20_20	35323	35601.2	35103	**33623**	**33764.0**	74.3	33972	34236.9	164.3
tai100_10	355783	357195.5	373462	**307448**	**309690.9**	1329.3	309629	311767.5	1369.3
tai100_20	430692	433701.8	440486	**377492**	**382019.0**	2431.3	381329	385474.7	2729.2
tai500_20	7840996	7879792.0	8407645	7040703	7075627.6	34421.2	–	–	–

9.1 Wykresy przebiegu EA

Poniżej przedstawiono przebiegi najlepszego uruchomienia algorytmu ewolucyjnego (best, avg, worst populacji w każdej generacji) dla trzech wybranych instancji.

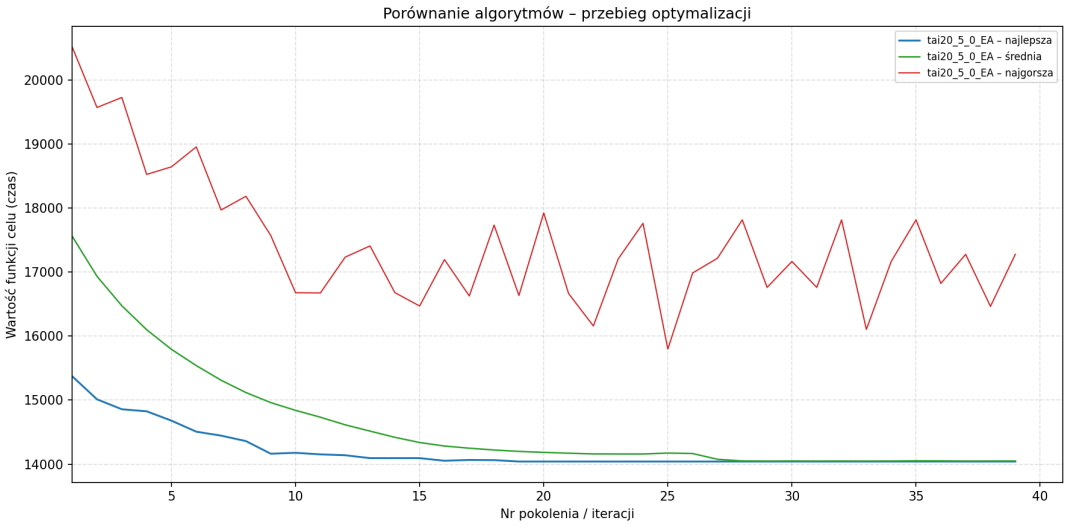

Rysunek 1: Przebieg EA dla instancji łatwej (tai20_5, pop=5000, gen=39)

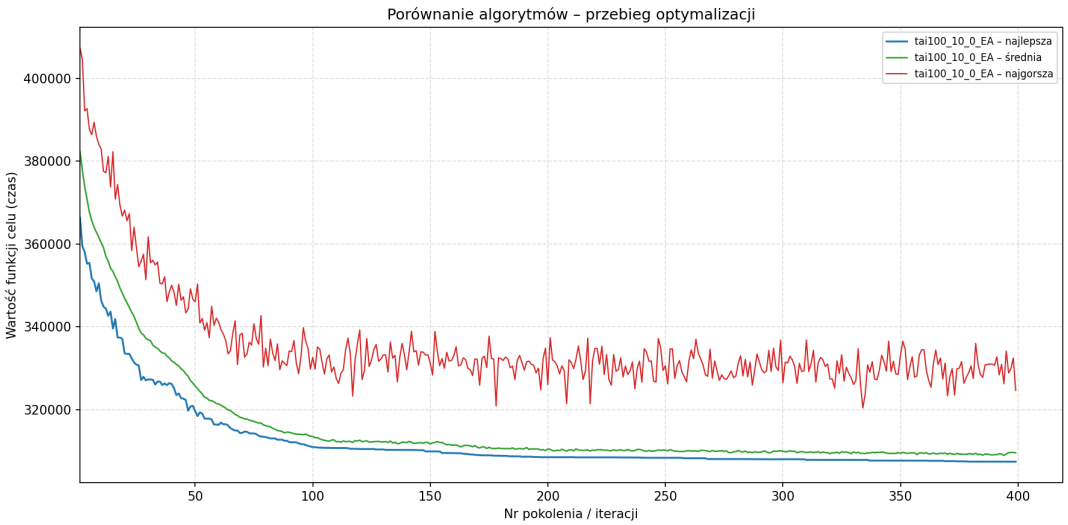

Rysunek 2: Przebieg EA dla instancji średniej (tai100_10, pop=500, gen=399)

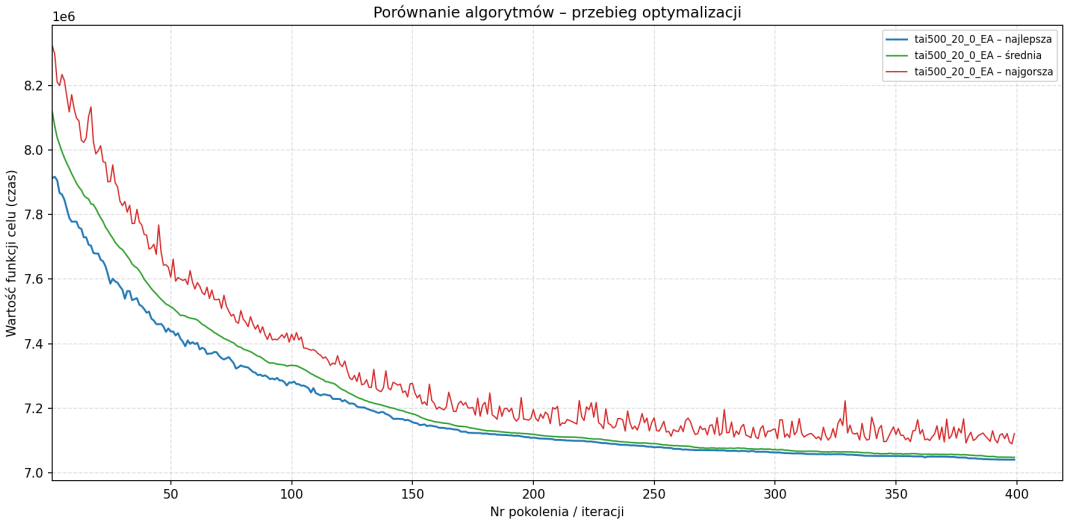

Rysunek 3: Przebieg EA dla instancji trudnej (tai500_20, pop=500, gen=399)

10 Analiza wyników i wnioski

10.1 Ranking algorytmów

Na podstawie wyników finalnego porównania ustalono następujący ranking skuteczności:

Instancje małe (tai20_*):

1. **EA** – wyraźnie najlepszy, z bardzo niskim odchyleniem standardowym (std=5.7–74.3). Duża populacja (5000) przy małej przestrzeni rozwiązań zapewniła doskonałe pokrycie i stabilność wyników.
2. **SA** – drugi, gorszy od EA o 1–2%.
3. **Random** – trzeci, zbliżony do greedy.
4. **Greedy** – najgorszy na tai20_10 i tai20_20 (24611 vs EA 20911 – różnica 17%!). Greedy padał ofiarą minimów lokalnych już na etapie konstrukcji.

Instancje średnie i trudne (tai100_*, tai500_20):

1. **EA** – nieznacznie lepszy od SA pod względem avg (tai100_10: 309691 vs 311768, tai100_20: 382019 vs 385475).
2. **SA** – zbliżony do EA.
3. **Random** – znacznie gorszy (tai100_10: avg 357196 vs EA 309691, różnica 15%).
4. **Greedy** – najgorszy (tai100_10: 373462 vs EA 307448, różnica 21%).

10.2 Kluczowe obserwacje

EA zdominowało SA na wszystkich dostępnych instancjach po strojeniu – stanowiło to odwrócenie wyniku sprzed strojenia, gdzie SA wygrywało na dużych instancjach. Strojenie parametrów EA (zwłaszcza per-instancja pop_size, Px i Pm) miało decydujący wpływ na jakość wyników.

Greedy okazało się najgorszą metodą mimo że jest deterministyczne i szybkie. Ograniczenie budżetowe przy greedy (mała liczba restartów), sprawia, że algorytm ten jest nieskuteczny.

Random okazało się zaskakująco dobrym punktem odniesienia – na instancjach tai20 osiągnęło wyniki zbliżone do greedy, a na tai100 było lepsze niż greedy. Wynikało to z bardzo dużej liczby ewaluacji ($B = 200\,000$) – losowe próbkowanie przy takim budżecie pokrywało przestrzeń lepiej niż deterministyczna heurystyka z małą liczbą restartów.

EA okazało się wyraźnie bardziej stabilne niż SA – odchylenie standardowe EA było konsekwentnie niższe (np. tai20_5: std=5.7 EA vs 102.6 SA). Duża populacja i mechanizm elitaryzmu (zawsze zachowywane najlepsze rozwiązanie) zapewniały powtarzalność wyników.

Strojenie per-instancja przyniosło znaczące korzyści. Porównując wyniki bazowe EA (pop=100, avg tai100_10=317724) z wynikami po strojeniu (pop=500, avg tai100_10=309691) zaobserwowano poprawę o 2.5%. Dla SA poprawa była mniejsza, co sugerowało że SA jest mniej wrażliwe na dobór parametrów przy odpowiednim budżecie obliczeniowym.